05

输入条件架构

从 iPER/Hi4D/TikTok 的离线资产到 Adapter 的五类运行时输入对象

蓝=输入 绿=编码 紫=推理
橙=Adapter 红=Detail 灰=冻结

A 离线来源与切片

SMPLest-X params.pt
全局组：beta/root/trans/camera → 26D
细节组：expression10 + jaw3
+ L45 + R45 → 103D

DWPose / 项目 keypoints_134
0:18 body • 18:24 foot
24:92 face68
92:113 left hand21
113:134 right hand21

nvdiffrast / geometry assets
normal3 • part14 • depth1 • mask1
目标 pose heatmaps 25

DeepGen VAE encodes source images
scene latent [B,16,h,w]
person latents [B,2,16,h,w]

ROI 条件构建
face/hand box: xyxy normalized
face expand15%，hand expand25%
valid threshold: face≥48/68, hand≥12/21
reference crop 224²

body 25

face + hands

B 五类输入对象

① ConditionBundle（全局结构）
A/B spatial [~~256,H/8,W/8~~] + masks
A/B global tokens [4,256]
relative tokens [2,256]
contact spatial/tokens + task token
person_valid / person_count

② AdapterIdentityCondition
（全局外观）
source_person_latents [B,2,16,h,w]
source_indices [B,2] ∈ [0,15]
同一样本有效人物不可重复

③ FaceHandDetailCondition（局部几何）
face [B,2,68,3]
hands [B,2,2,21,3]
smplx_detail [B,2,103]
source/target boxes [B,2,3,4]
region_valid [B,2,3] • source_indices

④ DetailReferenceBatch（局部外观）
images [B,2,3,R,3,224,224]
region order = face / left / right
R=1…3 • reference_valid 同形槽位

⑤ DeepGen step inputs（动态）
target noisy latent [B,16,Hlat,Wlat]
encoder_hidden_states [B,Ntext,4096]
pooled_projections [B,2048]
timestep [B] / denoise progress

运行时调节
geometry_strength
interaction_strength
detail / face / hand strength

C Adapter 内部准备结果

Prepared global conditioning
geometry_condition [B,144,Hlat,Wlat]
interaction_condition [B,144,Hlat,Wlat]
adapter_tokens [B,≤24,1536]
adapter_token_mask

PreparedFaceHandDetailConditioning
detail_condition [B,144,Hlat,Wlat]
detail_tokens [B,48,1536]
detail_token_mask [B,48]
region_masks [B,2,3,Htok,Wtok]
detail_valid [B]

Context 隔离
Geometry / Interaction: text + global adapter tokens
Detail: text + detail tokens only
局部 token 不改变旧分支输出

关键校验
detail-valid person 必须属于全局 person_valid
detail source_indices 必须匹配 identity source_indices
无 detail 或 detail_strength=0 → V6.3 路径

维度解释与当前边界

当前代码不是把“137 维关键点”整体塞进一个 encoder：全局分支保留 25 个身体 pose heatmaps；局部分支单独取 68 脸点 + 2×21 手点，并与 SMPL-X detail 103D 编码。这样避免高维局部信号稀释全局姿态条件。