

DeepGen 用于人物姿态图像编辑的适配性评估

面向三维人体控制与双人交互编辑的技术评估报告

评估对象 DeepGen 1.0 | 项目范围 研究目标三 | 资料截至 2026 年 9 月 8 日

评估结论

建议将 DeepGen 纳入第三阶段的优先原型基座，先完成小规模适配验证，再决定是否承担正式实验。它已有参考图像编辑路径，生成主干规模低于 6B，并提供可利用的控制残差接口；这些条件能够减少从头构建编辑模型的工作。单卡 84GB 适合启动冻结主干与轻量外挂的训练验证，但现阶段没有本项目的训练峰值显存或效果实测。

DeepGen 的主要风险是双人接触和外观保持能力尚未得到专项验证。公开通用编辑成绩也不足以支持其优于 Qwen-Edit 的结论。外挂能够增强目标姿态约束，但不能预先保证完全弥补基座在手指结构、遮挡重建和服饰细节上的能力差距。

评估维度	当前判断	对后续实验的含义
生成主干规模	符合当前口径	DiT 权重张量约 2.47B；全组件存储口径约 6.74B。
原生编辑与外挂接口	具备工程起点	保留参考图像路径，新增结构编码与残差注入分支。
双人交互与手部效果	需要专项验证	先检查身份交换、接触偏移和手部结构错误。
单卡 84GB 训练	值得直接验证	从 512 分辨率和小批次启动，再评估 1024。
Qwen Edit 类适配要求	存在验收边界	使用 Qwen 编码器不等于属于 Qwen Image Edit 模型家族。

评估依据与适用范围

本报告依据项目任务书、已提供的两份讨论材料、官方论文和公开代码编写。公开事实、权重元数据计算与拟议实验分别陈述。本文未运行 DeepGen 完整权重推理或训练，不将工程推断表述为性能实测。对于蒸馏路线，质量应按具体检查点评价，不能仅凭“蒸馏”判断优劣。

任务书要求完成与 Qwen-Edit 类模型的适配，并以 Qwen-Edit 为主观评测基线。若验收严格限定 Qwen-Image-Edit 家族，DeepGen 不能替代该项交付；若允许同类图像编辑模型，则可作为技术候选。前一项约束应在正式选型时落实。

1 模型结构与项目接口

DeepGen 以 Qwen2.5-VL 为视觉语言理解模块，通过 Stacked Channel Bridging（SCB，分层特征连接模块）向扩散 Transformer（DiT）提供语义条件；生成模块来源于 UniPic2-SD3.5M-Kontext。它具备图像编辑训练基础，因此本项目可以围绕已有参考图像条件增加几何控制。它并非 Qwen-Image-Edit 的小参数版本。

[1] DeepGen 官方项目与基准结果[2] DeepGen 技术报告 arXiv 2602.12205

组件	权重张量元素数	在本项目中的处理
生成 DiT	2,469,663,936	冻结，接收外挂输出的控制残差。
Qwen 视觉语言模块	3,754,622,976	冻结，保留发布版本的已合并权重。
SCB 连接模块	432,449,532	冻结，保留原有语义到生成条件的映射。
VAE 图像编解码器	83,819,683	冻结，编码源图和训练目标图。
合计	6,740,556,127	全组件统计，不作为主干 6B 限制的口径。

上表为已固定版本 safetensors 文件头中张量形状的乘积汇总，含存储层面的张量统计；共享参数与缓冲区仍应在模型加载后复核。其用途是核查体量和权重占用，不能替代运行时峰值测量。官方“3B+2B”的简写也不应直接用于精确显存预算。

[3] DeepGen Diffusers 权重与配置 固定版本

与第二阶段的衔接

第三阶段的输入应明确包含源图、两人的稳定身份编号、重定向后的 SMPL-X、目标相机、接触部位对应关系及有效性标记。若希望保留目标角色外观，源图中的角色编号必须与第二阶段输出一致。仅有两组人体参数而缺少相机或身份对应，无法稳定构造图像控制信号。

建议将网格投影成深度、法线、身体部位与人物实例图，并生成关节和接触区域提示。每个人的可见性、左右手和深度顺序需要保留。SMPL-X 描述人体表面，不描述服装外轮廓，训练时应允许衣物偏离裸身轮廓，避免把宽松服装压成身体形状。

保留原有外观路径

源图同时承担视觉语义条件与参考潜变量条件。后者参与生成 Transformer 的图像序列计算，是保留人物和服饰的现有基础。优先复用这条路径；只有身份和纹理的消融结果显示不足时，再增加按人物区分的外观特征分支。

[4] DeepGen Diffusers 推理与动态 Transformer 实现

2 外挂控制的适配方案

建议的首版结构

首版采用冻结 DeepGen 与可训练结构适配器。适配器融合目标深度、法线、人物编号、部位和接触提示，结合扩散时间步生成若干层的控制残差，注入 DiT。建议把 100M 至 300M 作为初始可训练参数预算，并通过实际参数统计约束规模；这个范围是工程方案，尚无充分证据说明它一定满足双人精细控制。

不同控制图优先在通道或紧凑特征层融合。接触关系还应编码为“人物 A 的左手—人物 B 的右肩”等部位对应，辅以局部接触热图。单张二值接触图无法完整表达参与者、左右侧和遮挡顺序。控制分支输出层采用零初始化或零门控，使训练初始行为接近原始编辑模型。

已存在的接口与必须修改的部分

已核查的动态 Transformer 接受 `block_controlnet_hidden_states`，并在部分 Transformer 块之后加到隐藏状态；同时提供梯度检查点路径。由此可以避免重新设计主干内部的全部控制机制，但仍需实现适配器、数据管线和训练入口。

[4] DeepGen Diffusers 推理与动态 Transformer 实现[5] DeepGen 动态 Transformer 源码

接口问题	适配要求
目标与参考图像序列拼接	残差应匹配目标 token、参考 token 与批内填充后的完整形状。首版可仅在目标区域输出非零残差。
Transformer 的特征组织	按实际层宽和序列长度投影；不能直接沿用 U-Net 多尺度特征的尺寸假设。
控制强度与条件丢弃	为不同几何信号设置消融开关；检查推理时 CFG 分支与训练时条件丢弃的一致性。
多视图和多控制图	同一目标相机渲染并同步裁剪。不能默认把每张控制图当作额外参考图直接拼入。

可以复用的研究工作

T2I-Adapter 可提供轻量条件编码和冻结生成器训练的设计参考；CFLD 可提供人物外观与姿态分离的实验思路及数据准备经验。它们的预训练外挂与 DeepGen 的层结构、序列组织和条件维度并不一致，现权重不能据此认定可直接加载。复用重点是数据处理、控制设计和评价协议。

[12] CFLD 姿态引导人物图像合成[13] T2I Adapter 官方实现

研究增量宜集中在双人身份绑定、接触部位对应和遮挡感知控制，以及在主干完全冻结时的有效注入方式。是否构成方法创新，需要结合后续消融与相关工作比较，单纯连接 SMPL-X 渲染器和现有控制接口不足以证明贡献。

3 效果证据与能力边界

官方发布的编辑基准可以证明 DeepGen 具备通用编辑能力，但不能直接回答其对拥抱、握手等任务的适配效果。下表为作者报告的分值，并非本项目复测；各列评价体系不同，不能横向相加。

模型	GEdit EN	ImgEdit	RISE	UniREdit
DeepGen SFT	7.12	4.09	13.3	77.5
DeepGen RL	7.17	4.14	10.8	75.7
Qwen Image Edit 2509	7.54	4.35	8.9	56.5

在上述结果中，DeepGen 的通用编辑分数低于 Qwen-Image-Edit 2509，推理编辑分数较高。这个差异支持其具备一定指令理解能力，却不能证明几何精度、身份保持或手部质量更好。RL 版本也并未在每项编辑指标上超过 SFT，后续应核对检查点来源并进行任务内比较。

[1] DeepGen 官方项目与基准结果

项目要求	DeepGen 可以利用的基础	最需要验证的失败情形
单人姿态变化	原生图像编辑与几何残差	原姿态残留，或姿态变对但服装纹理改变。
双人身份保持	源图参考潜变量	两人换脸、衣服串色、肢体归属错误。
拥抱与搂肩	目标深度与实例控制	前后关系错误，手臂消失或多出肢体。
握手与牵手	手部关节及接触区域提示	手指粘连，接触位置偏移，左右手混淆。
不同体型的重定向	目标人体形状与投影	回退到源人体比例，或破坏衣物形状。

对效果的合理预期

小幅、可见关节充分的单人动作适合作为接通控制的初始任务；双人整体构图与躯干方向是下一步验证对象。大角度转身、严重遮挡、交叉手指等情况需要重建源图中不存在的外观信息，应单独统计，不能以平均图像分数掩盖其失败。以上顺序是实验设计判断，不是模型已有能力分级。

主干冻结保留了基座参数，但不自动保证输出身份不变。控制残差过强仍可能覆盖外观条件。若提高控制强度持续导致身份或纹理损失，应优先检查条件冲突、数据对应和人物绑定，再考虑增加外挂容量。

4 数据复用与训练样本构建

现有数据能够减少采集和标注成本，但没有一个已核查的数据源能够直接覆盖“任意目标体型重定向后的双人真实编辑图像”。建议先利用同一人物或同一对人物的视频帧构造真实源图与目标图，再补充三维几何监督。

数据源	适合的用途	使用边界
CHI3D [8]	双人接触控制与验证	有双方 SMPL-X；第二人的网格属于仿真值。接触签名不是逐帧完整标注。
EgoBody [9]	真实双人外观与姿态配对	选择第三人称 Kinect 视图中双方可见的帧；不能把第一人称图像当作双人完整源图。
Hi4D [10]	近距离双人遮挡与交互	发布的人体参数为 SMPL，不能直接当作带完整手部标注的 SMPL-X。
BEDLAM [11]	几何控制预训练与体型覆盖	合成图像存在域差异；筛选稳定相机和合适人物实例。
DeepFashion 配对 [12]	单人姿态与服饰保持预实验	不能直接承担双人接触监督；三维参数需要另行估计。

CHI3D 的 631 段交互记录各包含一个建立接触的标注时间点，四个视角对应 2524 组图像与接触签名。可将这些标注点用于接触验证；对其余帧，从网格距离生成的接触标签应标为派生标签，并记录阈值和可信度，不能等同于人工标注。

[8] CHI3D 数据集与接触标注说明[9] EgoBody 数据集与第三人称视图说明[10] Hi4D 数据格式说明[11] BEDLAM 官方数据集[12] CFLD 姿态引导人物图像合成

推荐的数据单元

每个训练单元保存源图、真实目标图、目标 SMPL-X 与相机、两人身份对应、控制渲染图、接触标签来源及有效区域。源图与目标图优先来自同一人物组合、同一场景和同一相机。相机移动或人物出画的样本需要过滤或显式建模，否则背景变化会混入姿态学习目标。

在有真实目标图的阶段，使用该图对应的目标几何监督编辑。第二阶段任意重定向产生的体型和动作组合通常没有真实目标照片，应作为泛化测试，或通过可控合成数据补充，不能将不对应的原视频帧当作目标图。

数据划分和准入

按人物组合与视频序列划分训练和测试，保留不同身高差、接触动作和遮挡程度。连续帧不应随机分散到两侧。下载前记录各数据集、人体模型和权重的许可及项目用途范围；可公开获取不等于可以用于任意企业项目训练。

5 冻结主干的训练实现

先建立可验证的冻结边界

冻结 DiT、视觉语言模块、SCB 和 VAE，只把新增适配器参数交给优化器。发布模型中已经合并的 VLM LoRA 属于所选基座权重，应随基座冻结；不要替换成未合并的原始 Qwen 编码器而仍假定模型等价。实际加载代码优先读取权重目录内的合并 VLM。

[4] DeepGen Diffusers 推理与动态 Transformer 实现

原生 SFT 配置包含 `freeze_transformer=False` 和 LoRA 设置，其目的并非本项目的外挂训练。因此不能直接启动官方 SFT 配置后声称主干保持不变。需要独立配置冻结边界、优化器参数组、适配器保存格式以及推理接入方式。

[6] DeepGen 原生 SFT 配置[7] DeepGen 训练说明

冻结权重仍需要反向传播

当适配器残差进入 DiT 后，损失到适配器之间的计算图必须保留。将 DiT 全部包在 `no_grad` 中会切断这条路径。正确做法是冻结参数的 `requires_grad`，同时允许对输入残差求梯度；仅对无需回传的源图编码等路径关闭梯度。公开推理 pipeline 使用 `no_grad`，训练必须调用可微的底层模块。

[4] DeepGen Diffusers 推理与动态 Transformer 实现[14] PyTorch 自动微分机制

训练目标与推进顺序

首轮沿用原模型的流匹配或去噪训练定义，核对噪声插值、时间步采样、预测目标和潜变量缩放。一个训练样本随机选择一个时间步即可建立基础监督，初期不需要把整条多步采样过程展开反向传播。

先用单人配对图验证结构控制，再加入双人整体姿态，最后提高接触和手部样本比例。对手部或接触区域增加损失权重时，应区分真实标注与伪标签；潜空间加权误差只是局部训练代理，不能作为手部解剖结构正确的保证。

身份、衣物和背景损失应在对应区域与有效可见区域内定义。姿态变化后直接逐像素约束整个人体会惩罚合理变化。需要图像空间辅助监督时，可对适当噪声区间的预测图进行低频解码评估，并计入其额外显存与计算成本。

验明训练确实有效

训练前后核对基座参数校验值；完成一次反向后确认适配器有有效梯度而基座没有参数梯度；关闭适配器应恢复原始编辑行为。每个检查点同时保存基座版本、控制图规范和适配器配置，以便在另一台机器上重现。

6 训练显存预算与 84GB 设备适配

建议按单卡 84GB 资源推进首轮实验，而非先追加硬件。该判断基于约 2.47B 的冻结 DiT、可缓存的编码路径和 100M 至 300M 适配器设定。它说明资源条件值得开展实测，不代表已证明 1024 分辨率的任意配置都能运行。

可以计算的静态占用

项目	计算假设	估算占用
全套冻结权重	所有组件统一 BF16，每元素 2 字节	12.56 GiB
仅 DiT 驻留	编码结果已缓存且相应模块移出 GPU	4.60 GiB
100M 适配器训练状态	保守按每参数 16 字节预算	1.49 GiB
300M 适配器训练状态	同上，含梯度与优化器等状态	4.47 GiB
全权重加 300M 适配器	以上静态项求和	17.03 GiB
DiT 加 300M 适配器	缓存条件下的静态项求和	9.07 GiB

GiB 按 2^{30} 字节计算。16 字节是用于预算的保守混合精度 Adam 状态口径，实际取决于优化器实现和主权重副本。发布连接模块以 FP32 存储；若加载后仍保留 FP32，全权重静态项比上表增加约 0.81 GiB。文件体积、权重占用和训练峰值必须分别报告。

训练峰值还包含 DiT 与适配器激活、注意力临时张量、图像编码、图像空间辅助损失、内存分配器预留和运行时开销。现有核查无法给这些动态项一个可靠的单值，因此不把 17.03 GiB 表述为训练只需 17GB。

分辨率为什么影响明显

按 VAE 八倍下采样、DiT 两倍分块计算，512 方图约 1024 个图像 token，1024 方图约 4096 个。若同时使用同分辨率源图与目标图，图像序列分别约 2048 和 8192 个 token，另有语义条件。高效注意力减少显式注意力矩阵的存储，但序列加长仍显著增加计算与激活成本。

[3] DeepGen Diffusers 权重与配置 固定版本[4] DeepGen Diffusers 推理与动态 Transformer 实现

建议的设备使用顺序

先测 512×512、微批次 1、BF16、梯度检查点和高效注意力；通过后测试 768 和 1024。梯度累积用于增加有效批次。将冻结且确定性的 VLM、SCB 和 VAE 编码离线缓存，可进一步腾出显存，但缓存必须与提示词、裁剪、分辨率和模型版本一致。

以 48GB 作为 512 原型的可尝试档位，以 80 至 84GB 作为 1024 原型的优先资源档位；二者均为规划建议，不是最低显存实测。最终以设备实际可用容量为准，连续训练稳定后留出约 10%至 15%余量。

7 分阶段验证与正式实验设计

推荐用四步验证决定是否继续投入。下表样本量为启动建议，不代表达到统计显著性所需的最终规模。前两步通过后，再扩大双人数据和训练时长。

阶段	建议设置	应取得的证据
原生能力复现	20 例单人、40 例双人；固定模型、提示和随机种子	确定原始外观保持水平，记录接触与手部失败类型。
外挂连通验证	16 至 32 组配对图过拟合；512、微批次 1	主干校验值不变；梯度有效；更换目标控制能产生对应变化。
小规模有效性	500 至 2000 组去重训练对；按人物与序列留出验证集	相同基座下，姿态与交互改善，同时身份和服饰没有不可接受退化。
正式对照	确定数据与协议后扩大样本；多随机种子	与消融及 Qwen-Edit 基线比较，报告置信区间与失败分布。

必须保留的对照

同一 DeepGen 基座下比较原生编辑、仅二维姿态控制、三维几何控制、加入接触关系的完整方案。分别移除人物编号、深度或接触条件，可以判断增益来自哪类信号。保持训练数据和主要计算设置一致，单独报告可训练参数量。

Qwen-Edit 对照需固定具体版本、输入信息、提示词、输出分辨率、采样预算及选择样本的规则。原生基线与额外几何条件方案的比较属于完整系统比较，不应表述为同等输入下的纯基座优劣。若基线可以接收目标渲染图，应另列信息尽量匹配的对照。

评价应对应任务书

姿态采用可见关节的误差或正确率；身份按人物 A 和 B 分别匹配评价；服装和背景在有效区域评价。严重遮挡下的姿态估计与接触重建会产生评估器误差，应将其作为代理指标，并保留人工核验。整体图像相似度不能代替接触正确性。

主观盲评分别记录身份可辨识、动作准确、交互自然及手部结构。任务书的“相比 Qwen-Edit 基线高于 5%”应明确分母、平局处理及相对提升或百分点口径，不能自行改写为固定 55% 胜率。统计应按案例或人物组合聚类，避免把同一案例多个随机种子视作完全独立样本。

显存测量与停止条件

预热并实际执行优化器更新后，连续运行至少 100 步，记录 max_memory_allocated、max_memory_reserved、设备侧占用、每步时间和精度设置；另测验证采样峰值。若控制失效，先排查坐标、残差形状和梯度；若几何已对齐却持续出现换脸或手部错误，再决定扩展外观分支或更换基座。

8 选型建议与依据索引

技术选型上，建议以 DeepGen 完成首轮可行性实验。它使主要工作集中在几何条件编码、双人接触控制和评价，而无需重新训练一个完整图像编辑模型。84GB 设备足以支持有价值的验证起点；训练规模应由第 7 节的峰值测量与效果结果逐步确定。

正式实验主基座的确定应同时满足三个条件：冻结边界与控制接口已验证；在留出人物上的结构改善没有明显损害外观；项目方确认其满足模型适配范围。若严格要求 Qwen-Image-Edit 家族，DeepGen 仍可用于方法预研，但不能宣称已经完成该家族的适配交付。

版本与可复核材料

权重核查版本为 `deepgenteam/DeepGen-1.0-diffusers`，revision `85c2ed257b9406d8531965c68e140dc7fdb81382`。代码核查使用 DeepGen GitHub revision `fbaaaf4ae1c79450d6a34b30beb4f59840568c69`。Diffusers 发行版与论文 SFT 或 RL 检查点的具体映射应在下载时再次核对，不能仅按仓库名称推定。

项目依据为《人物图像姿态编辑任务书_v3.docx》及两份已提供的讨论材料。参数统计方法与结果已保存在同目录上一级的 `audit_checkpoint_headers.py` 和 `checkpoint_audit.json`。当前证据包括公开资料与元数据核查，不包括目标设备训练实测。

公开依据

- [1] DeepGen 官方项目与基准结果
- [2] DeepGen 技术报告 [arXiv 2602.12205](#)
- [3] DeepGen Diffusers 权重与配置 固定版本
- [4] DeepGen Diffusers 推理与动态 Transformer 实现
- [5] DeepGen 动态 Transformer 源码
- [6] DeepGen 原生 SFT 配置
- [7] DeepGen 训练说明
- [8] CHI3D 数据集与接触标注说明
- [9] EgoBody 数据集与第三人称视图说明
- [10] Hi4D 数据格式说明
- [11] BEDLAM 官方数据集
- [12] CFLD 姿态引导人物图像合成
- [13] T2I Adapter 官方实现
- [14] PyTorch 自动微分机制